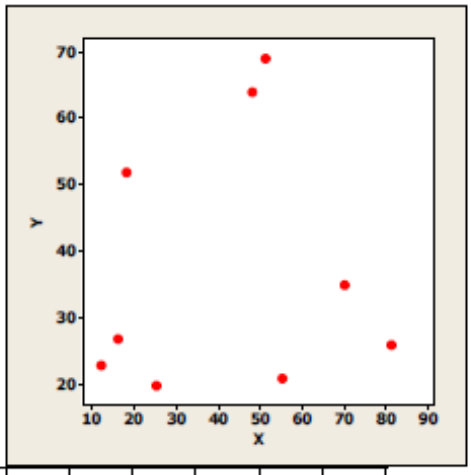
ESEMPIO con 9 punti.
Consideriamo i seguenti dati:

	X	Y
1	12	23
2	25	20
3	16	27
4	81	26
5	55	21
6	70	35
7	18	52
8	48	64
9	51	69



Qui a fianco è riportata la matrice dei quadrati delle distanze euclidee fra i punti (è più comodo usare i quadrati delle distanze).

	1	**2**	**3**	**4**	**5**	**6**	**7**	**8**	**9**
1	0	178	32	4770	1853	3508	877	2977	3637
2	178	0	130	3172	901	2250	1073	2465	3077
3	32	130	0	4226	1557	2980	629	2393	2989
4	4770	3172	4226	0	701	202	4645	2533	2749
5	1853	901	1557	701	0	421	2330	1898	2320
6	3508	2250	2980	202	421	0	2993	1325	1517
7	877	1073	629	4645	2330	2993	0	1044	1378
8	2977	2465	2393	2533	1898	1325	1044	0	34
9	3637	3077	2989	2749	2320	1517	1378	34	0

Algoritmo di aggregazione

Una volta scelto il metodo di aggregazione fra le classi, i passi dell'algoritmo di aggregazione gerarchica ascendente di n punti sono i seguenti:

passo 1: si costruisce la matrice delle distanze fra gli n punti; si cercano i due punti più vicini e li si aggrega in un'unica classe;

passo s: a partire dalla matrice delle distanze del passo s-1 si costruisce una nuova matrice delle distanze: si ricalcolano le distanze della classe costruita al passo precedente con le altre classi, le altre distanze rimangono inalterate. Si cercano le due classi più vicine e si aggregano in un'unica classe;

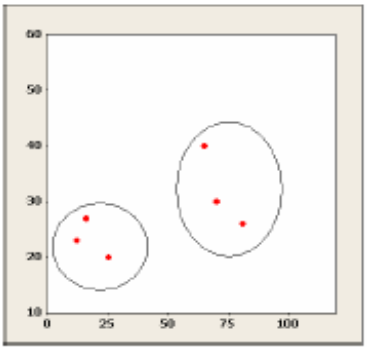
passo n-1: si hanno solo due classi che vengono raggruppate nella classe costituita da tutti i punti iniziali.

Distanza fra classi

Come definiresti la distanza fra due classi di punti?

Prova a fare delle ipotesi per il semplice esempio a fianco.

In genere la distanza fra classi viene definita in due passi: prima si definisce la distanza fra un punto e una classe formata da due punti; successivamente si definisce la distanza fra due classi.



In seguito denoteremo con "classe" anche una classe formata da un singolo punto.
Indichiamo con:

- x, y, z, ... , x_i, x_j, ... i punti,
- d(x,y) la distanza fra due punti x e y; in genere sarà la distanza euclidea
- C_{xy} la classe ottenuta dal raggruppamento di x e y,
- C_A e C_B due classi con rispettivamente n_A e n_B punti e con baricentri $\overline{X}_A$ e $\overline{X}_B$:

$$\overline{X}_A = \frac{1}{n_A} \sum_{x_i \in A} x_i \qquad \overline{X}_B = \frac{1}{n_B} \sum_{x_i \in B} x_i$$

- $\sum_{x_i \in A}$ la somma su tutti i punti di C_A

Ricordiamo che i punti appartengono a uno spazio a p dimensioni e quindi anche i baricentri sono punti a p dimensioni, le cui coordinate sono i baricentri delle singole variabili.

Considerate l'esempio sulle regioni e verificate le coordinate dei baricentri delle tre classi.

Molti sono i metodi per aggregare le classi, infatti varie sono le possibilità di definire una distanza fra due classi.

- Metodo della *distanza minima* o *single linkage*

La distanza fra la classe formata dai punti x e y e un punto z è definita come:

$$D(C_{xy},z) = \min \{ d(x,z), d(y,z) \}$$

La distanza fra C_A e C_B è la minima distanza fra ogni punto di C_A e ogni punto di C_B

- Metodo della *distanza massima* o *complete linkage*

La distanza fra la classe formata dai punti x e y e un punto z è definita come:

$$D(C_{xy},z) = \max \{ d(x,z), d(y,z) \}$$

La distanza fra C_A e C_B è la massima distanza fra ogni punto di C_A e ogni punto di C_B

- Metodo della *distanza media* o *average linkage*.

La distanza fra la classe formata dai punti x e y e un punto z è definita come:

$$D(C_{xy},z) = \frac{d(x,z) + d(y,z)}{2}$$

La distanza fra C_A e C_B è la distanza media fra coppie di punti, uno in C_A e uno in C_B

- Metodo dei *centroidi*

In generale la distanza fra C_A e C_B è la distanza fra i baricentri C_A e C_B:

$$D(C_{xy},z) = d(\overline{x}_A, \overline{x}_B)$$

N.B. : quanto segue è stato realizzato con il metodo della distanza minina.

	1	2	3	4	5	6	7	8	9
1	0	178	32	4770	1853	3508	877	2977	3637
2	178	0	130	3172	901	2250	1073	2465	3077
3	32	130	0	4226	1557	2980	629	2393	2989
4	4770	3172	4226	0	701	202	4645	2533	2749
5	1853	901	1557	701	0	421	2330	1898	2320
6	3508	2250	2980	202	421	0	2993	1325	1517
7	877	1073	629	4645	2330	2993	0	1044	1378
8	2977	2465	2393	2533	1898	1325	1044	0	34
9	3637	3077	2989	2749	2320	1517	1378	34	0

Matrice iniziale

		C_1						
	1-3	**2**	**4**	**5**	**6**	**7**	**8**	**9**
C_1 **1-3**	0	130	4226	1557	2980	629	2977	2989
2	130	0	3172	901	2250	1073	2465	3077
4	4226	3172	0	701	202	4645	2533	2749
5	1557	901	701	0	421	2330	1898	2320
6	2980	2250	202	421	0	2993	1325	1517
7	629	1073	4645	2330	2993	0	1044	1378
8	2977	2465	2533	1898	1325	1044	0	34
9	2989	3077	2749	2320	1517	1378	34	0

Passo 1:
Si aggregano i punti 1 e 3 nella classe C_1.

ecc. ecc.

L'aggregazione dei punti può essere sintetizzata nel seguente modo:

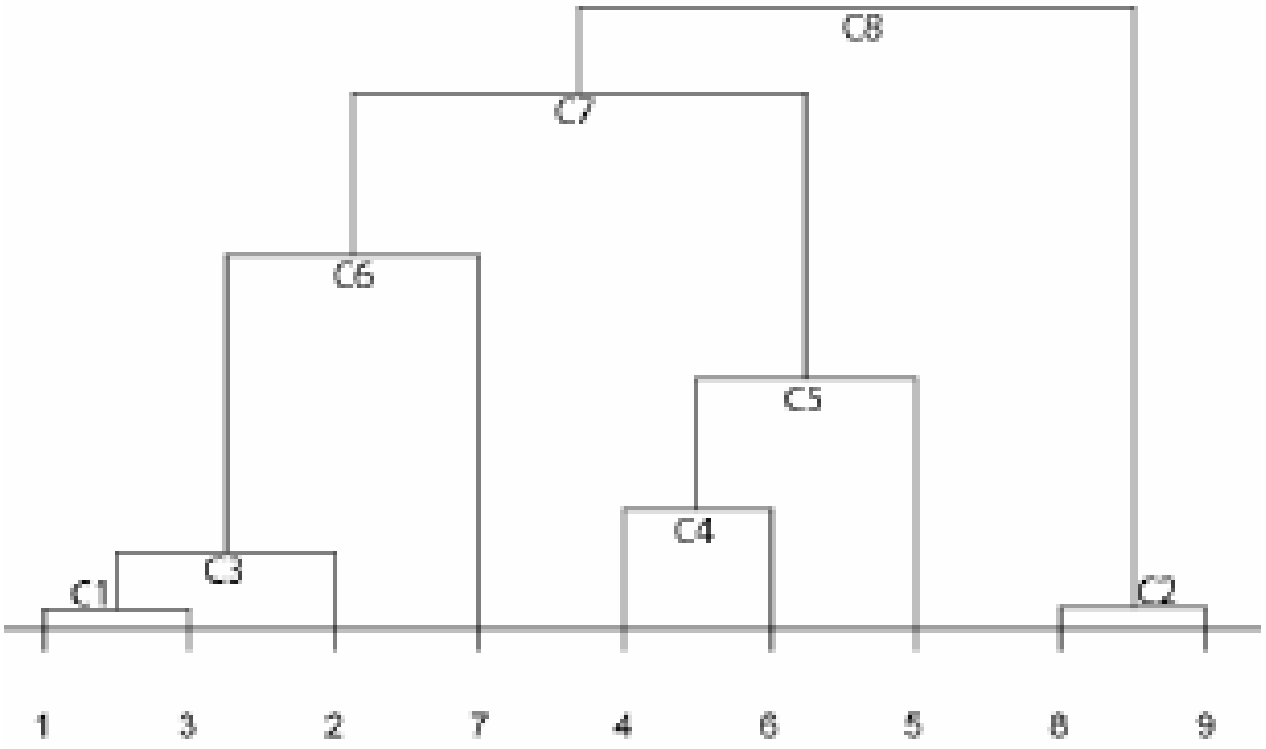
Passo 0: {1}, {2}, {3}, {4}, {5}, {6}, {7}, {8}, {9}
Passo 1: {1, 3}, {2},{4}, {5}, {6}, {7}, {8}, {9}
Passo 2: {1,3}, {2},{4}, {5}, {6}, {7}, {8 , 9}
Passo 3: {1, 2, 3}, {4}, {5}, {6}, {7}, {8 , 9}
Passo 4: {1, 2, 3}, {4, 6}, {5}, {7}, {8 , 9}
Passo 5: {1, 2, 3}, {4, 5 , 6}, {7}, {8 , 9}
Passo 6: {1, 2, 3, 7}, {4, 5, 6}, {8 , 9}
Passo 7: {1, 2, 3, 4, 5, 6 , 7 }, {8 , 9}
Passo 8: {1, 2, 3, 4, 5, 6 , 7 , 8 , 9}

È possibile assegnare a ciascuna classe $C_1, C_2, \dots, C_{n-1}$ un *indice di aggregazione* a_i corrispondente alla distanza fra le due classi aggregate nella loro costruzione.

Indichiamo con $a_1, a_2, \dots, a_{n-1}$ gli indici di aggregazione.

A fianco sono riportati gli indici di aggregazione corrispondenti all'esempio precedente, dove si è utilizzato il metodo della distanza minima.

C1	32	{1, 3}
C2	34	{8, 9}
C3	130	{1, 2, 3}
C4	202	{4, 6}
C5	421	{4, 5 , 6}
C6	629	{1, 2, 3, 7}
C7	901	{1, 2, 3, 4, 5, 6, 7 }
C8	1044	{1, 2, 3, 4, 5, 6, 7, 8, 9}



Esercizio:

Ripetere l'esercizio utilizzando come metrica il metodo del baricentro, invece che della distanza minima, disegnare il nuovo dendrogramma e valutarne le differenze.